

Machine Learning HW1

TAs

ntu.mlta@gmail.com

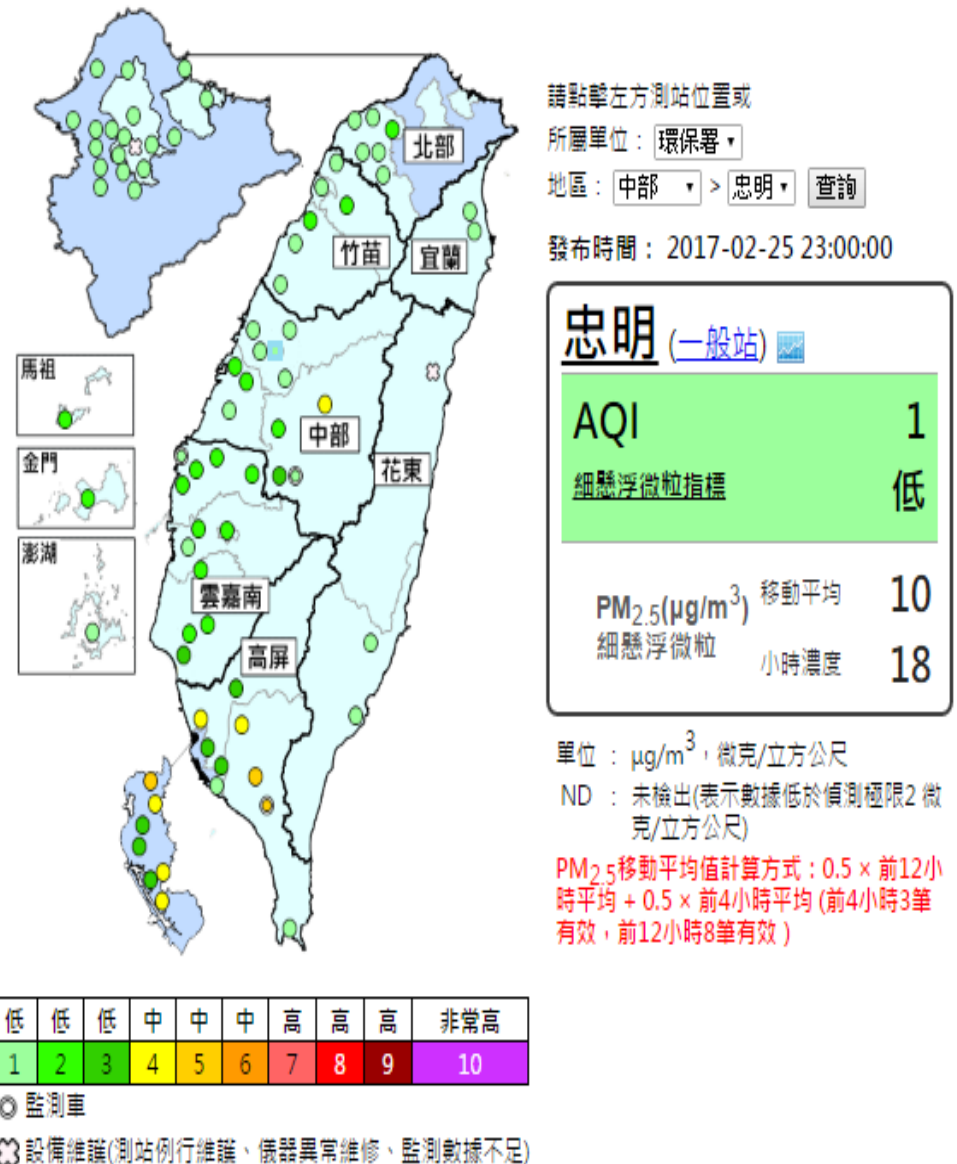
Outline

- ❖ hw1介紹
- ❖ train/test data
- ❖ Kaggle
- ❖ 作業規定、繳交格式、批改方式
- ❖ 配分
- ❖ FAQ
- ❖ Github (請看hw0影片)

發布時間：2017/02/25 23:00
即時細懸浮微粒指標

Task - Predict PM2.5

本次作業的資料是從中央氣象局網站下載的真實觀測資料，希望大家利用linear regression或其他方法預測PM2.5的數值。



Data 簡介

- ❖ 本次作業使用豐原站的觀測記錄，分成train set跟test set，train set是豐原站每個月的前20天所有資料。test set則是從豐原站剩下的資料中取樣出來。
- ❖ **train.csv**：每個月前20天的完整資料。
- ❖ **test_X.csv**：從剩下的資料當中取樣出連續的10小時為一筆，前九小時的所有觀測數據當作feature，第十小時的PM2.5當作answer。一共取出240筆不重複的test data，請根據feature預測這240筆的PM2.5。

Training Data


[illegible]

Testing Data

	A	B	C	D	E	F	G	H	I	J	K	L	M
1	id_0	AMB_TEM	15	14	14	13	13	13	13	13	12		
2	id_0	CH4	1.8	1.8	1.8	1.8	1.8	1.8	1.8	1.8	1.8		
3	id_0	CO	0.36	0.35	0.34	0.33	0.33	0.34	0.34	0.37	0.42		
4	id_0	NMHC	0.11	0.09	0.09	0.1	0.1	0.1	0.1	0.11	0.12		
5	id_0	NO	0.6	0.4	0.3	0.3	0.3	0.7	0.8	0.8	0.9		
6	id_0	NO2	9.3	7.1	6.1	5.7	5.5	5.3	5.5	7.1	7.5		
7	id_0	NOx	9.9	7.5	6.4	5.9	5.8	6	6.2	7.8	8.4		
8	id_0	O3	36	44	45	44	44	44	43	40	38		
9	id_0	PM10	51	51	31	40	34	51	42	36	30		
10	id_0	PM2.5	27	13	24	29	41	30	29	27	28		
11	id_0	RAINFALL	NR	NR	NR	NR	NR	NR	NR	NR	NR		
12	id_0	RH	75	71	71	73	74	74	74	74	74		
13	id_0	SO2	1.2	1.2	1.2	1.6	1.5	1.5	1.5	1.6	1.6		
14	id_0	THC	1.9	1.8	1.8	1.9	1.9	1.9	1.9	1.9	1.9		
15	id_0	WD_HR	116	114	112	109	111	104	107	108	104		
16	id_0	WIND_DIR	115	113	105	102	106	106	112	113	106		
17	id_0	WIND_SPEED	2.6	2.2	2	1.9	2.4	2.4	2.5	2.8	2		
18	id_0	WS_HR	2.1	2.4	2.2	1.9	2.3	2.3	2.5	2.5	2.3		
19	id_1	AMB_TEM	12	12	12	13	14	15	14	14	13		
20	id_1	CH4	1.8	1.8	1.9	1.9	1.8	1.8	1.8	1.8	1.8		

Submission format

- ❖ 預測test set中的240筆PM2.5，上傳至Kaggle。
 - 上傳格式為csv
 - 第一行必須是 id,value
 - 第二行開始，每行分別為id及預測數值，以逗點分開
- ❖ 範例格式：



```
sampleSubmission.csv x
1 id,value
2 id_0,0
3 id_1,0
4 id_2,0
5 id_3,0
6 id_4,0
7 id_5,0
8 id_6,0
9 id_7,0
10 id_8,0
```

Kaggle

- ❖ 網址：<https://www.kaggle.com/c/ml-2017fall-hw1>
- ❖ 請至kaggle創帳號登入 (務必使用@ntu.edu.tw信箱)
- ❖ 個人進行、不須組隊
- ❖ 隊名：學號_任意名稱 (ex.b02901000_gai)，旁聽同學則避免使用此命名原則
- ❖ 每日上傳上限5次
- ❖ test.csv的240筆資料分為：120筆public、120筆private
- ❖ Leaderboard上顯示的是public的分數，在死線前可選擇兩份答案作為private的評分依據
- ❖ 最後計分排名將將會考慮到public以及private的成績
- ❖ kaggle deadline：10/12/2017 11:59:00 PM (GMT+8)
- ❖ github code & report deadline：2017/10/13 11:59:00 (GMT+8)

請填寫github url表單：<https://goo.gl/forms/LOX5W6ByDPSNWA6N2>

github url回應：<https://ppt.cc/fTfDNx>

#請每位修課同學務必填寫，hw0填過的也再填一次

作業規定

- ❖ Only **Python 3.5+** available
- ❖ 請實作linear regression，方法限定使用**Gradient Descent**。
- ❖ 若想嘗試其他方法也可以，但是仍然需實作linear regression。
- ❖ 不能使用現成套件，只能使用numpy、scipy以及pandas。
(Standard library可以)
(numpy.linalg.lstsq是不可以用的!!!)
若需要使用其他套件，請在Deadline前寄信至助教信箱詢問，並請簡述原因。
- ❖ **版本要求：**
Python 3.5+
numpy 1.13

繳交格式

1. **Kaggle deadline : 10/12/2017 11:59:00 PM (GMT+8)**

Github code & report deadline : 2017/10/13 11:59:00 (GMT+8)

Github commit為local端時間，請注意你電腦時間，並且上Github確認
助教會在Deadline一到就clone所有程式，並且**不再重新clone任何檔案**

2. 你的Github上**至少**需要有下列三個檔案：

ML2017FALL/hw1/report.pdf (請按照page. 13提供之template撰寫)

ML2017FALL/hw1/hw1.sh

ML2017FALL/hw1/hw1_best.sh

如果你有其他程式檔案，請一併上傳，e.g. xxx.py等等。另外，請不要上傳與作業無關檔案以及data

3. 請各位自行跑training部分，儲存訓練完的模型參數，一併上傳至github，hw1.sh & hw1_best.sh僅執行testing部分。

批改方式

1. test data會shuffle過，請勿直接輸出事先存取的答案
2. 助教批改程式時，會用下列的方法執行：

```
bash hw1.sh [input file] [output file]  
bash hw1_best.sh [input file] [output file]
```

input file : 助教提供test.csv的路徑

output file : 助教提供output的路徑

e.g. 如果為 `bash hw1.sh ./data/test.csv ./result/res.csv`

則hw1.sh 最後需要產生一個 res.csv的檔案在result資料夾中

3. hw1.sh與hw1_best.sh皆需要在**3分鐘內**跑出結果，否則不會拿到分數
4. 請勿在程式內寫死路徑、並且只能output在助教給定的路徑，不然會有permission denied的問題！

配分 (5%) - kaggle

❖ Kaggle Rank :

- (0.8%) 超過public leaderboard的simple baseline分數
- (0.8%) 超過public leaderboard的strong baseline分數
- (0.8%) 超過private leaderboard的simple baseline分數
- (0.8%) 超過private leaderboard的strong baseline分數
- (0.8%) 10/5 23:59 前超過public simple baseline

- (1%) kaggle排名前五名(且願意上台跟大家分享的同學)

❖ hw1.sh的結果必須超過public simple baseline，且hw1_best.sh需要重現在kaggle上面的成績，否則程式部分0分，report部分也會是部分給分

配分 (5%) - report

❖ report.pdf : PDF檔!!!!!!!

(限制：中文(非中文字母語者用英文)&不能超過2頁、請使用template作答)

- 請實做以下兩種不同feature的模型，回答第 (1) ~ (3) 題：
 - 抽全部9小時內的污染源feature的一次項(加bias)
 - 抽全部9小時內pm2.5的一次項當作feature(加bias)
- (1) 記錄誤差值 (RMSE)(根據kaggle public+private分數)，討論兩種feature的影響
- (2) 將feature從抽前9小時改成抽前5小時，討論其變化
- (3) Regularization on all the weight with $\lambda=0.1$ 、 0.01 、 0.001 、 0.0001 ，並作圖顯示訓練後的差別(with RMSE)
- (4) 證明linear regression的close form

❖ Report template :

<https://ppt.cc/fbdOZx>

Other policy

- ❖ script 錯誤，kaggle分數直接0分。若是格式錯誤，請在公告時間內找助教修好，修完kaggle分數*0.7。
- ❖ Kaggle超過deadline可以繼續上傳但不計入成績。
- ❖ Github遲交一天(*0.7)，不足一天以一天計算，不得遲交超過兩天，有特殊原因請找助教。
- ❖ Github遲交表單：<https://goo.gl/forms/mq0F6u82AKiw4tt33> (遲交才必需填寫)
遲交請「先上傳程式」至Github再填表單，助教會根據表單填寫時間當作繳交時間。

FAQ

1. 如果只有做一個方法是否需要繳交兩份script？

Ans.

是的。如果只有做linear regression，kaggle上的分數也是linear regression 的話，也麻煩交兩份script。

2. 表單填錯怎麼辦？

Ans.

請直接重新填即可，會以最新的表單為準。

提醒，表單只是蒐集各位github repo url，不需每次git push都填一次表單。

再次提醒，修課同學一定都要填寫！

小老師制度 (手把手教學)

- ❖ 在10/4以前超過simple baseline並願意在10/6在上課時間教導同學撰寫作業一程式，請填寫一下表單：<https://goo.gl/forms/epctvoGTRxeDsFIH2>
- ❖ 10/5將公布小老師名單在作業網頁，人數太多將以符合以下標準的同學為主：
 1. 沒有當過小老師
 2. kaggle成績排名較高
- ❖ 小老師當次成績 +1%